

第六讲：非线性优化

从“有一个近似解”到“让所有观测尽量自洽”

这一讲是视觉 SLAM 后端的数学地基。前端经由特征匹配、PnP 或三角化给出相机位姿和地图点的初值；后端把所有带噪声的观测同时放进一个目标函数中，寻找整体最合理的状态。

一句话主线：非线性优化就是不断微调状态，使模型预测与真实观测之间的残差尽可能小。

一、它到底在优化什么？

设第 k 帧相机位姿为 T_k ，地图点为 P_j 。观测到的像素 z_{kj} 与根据当前状态投影得到的预测像素 $h(T_k, P_j)$ 一般不会相同。二者之差称为残差 (residual) 或重投影误差。

$$r_{kj}(T_k, P_j) = z_{kj} - h(T_k, P_j)$$

例如实际像素是 (100, 200)，预测为 (103, 198)，则残差为 (-3, 2)。优化不要求某一个观测绝对为零，而是让所有观测残差的平方和尽可能小：

$$\min_x F(x) = 1/2 \cdot \sum_i ||r_i(x)||^2$$

这里 x 可以只包含一个位姿，也可以同时包含所有位姿和所有地图点。后者就是后续 Bundle Adjustment (BA) 的基本形式。

二、它为什么是“非线性”的？

状态从世界坐标变到相机坐标需要 $SE(3)$ 变换，再经过透视投影 $u = f_x X/Z + c_x$ 、 $v = f_y Y/Z + c_y$ 。旋转、除以深度和投影共同使残差对位姿与点坐标呈非线性关系，无法一次用普通线性方程直接解出。

$$\text{世界点 } P_w \rightarrow P_c = T \cdot P_w \rightarrow \text{归一化投影} \rightarrow \text{像素预测 } h(T, P)$$

因此我们从一个可用初值出发，在它的邻域内把复杂函数近似成线性函数，求一个小的更新量，再迭代。

三、最小二乘的迭代框架

无论使用哪种优化器，外层循环都很一致：

初值 $x_k \rightarrow$ 计算残差 $r(x_k) \rightarrow$ 计算 Jacobian $J \rightarrow$ 解增量 $\Delta x \rightarrow$ 更新 $x_{(k+1)} \rightarrow$ 检查是否收敛

Jacobian (雅可比矩阵) 描述“状态微小变化时，残差会怎样变化”。它是从当前局部信息推断更新方向的关键。

$$r(x + \Delta x) \approx r(x) + J(x) \Delta x$$

线性化后，原来的非线性最小二乘近似为一个线性最小二乘问题。需要注意： Δx 是局部增量，对位姿通常要通过李代数的加法更新到 SE(3)，而不是直接把两个变换矩阵相加。

四、三种常见下降策略

方法	局部模型与增量	直觉与特点
最速下降	Δx 沿 $-J^T r$ 的方向，另选步长。	只利用一阶信息；稳健直观，但在狭长谷底常很慢。
Gauss-Newton	$H \Delta x = -J^T r$ ，其中 $H \approx J^T J$ 。	用一阶线性化得到二阶曲率近似；接近解时通常很快，但依赖好初值， H 可能病态或不可逆。
Levenberg-Marquardt	$(J^T J + \lambda I) \Delta x = -J^T r$ 。	给 GN 加阻尼/信赖域： λ 大时更像梯度下降， λ 小时更像 GN，通常更稳健。

LM 中通过比较“实际下降”和“局部模型预测下降”的一致性来调整 λ 或信赖域半径：局部模型可靠就扩大步子，不可靠就缩小步子。这是它比纯 GN 更稳定的原因。

五、在 SLAM 系统中的位置

前端负责从图像中产生约束并给出初始估计；后端以这些约束为输入，通过优化输出更准确、一致的位姿和地图。

图像 $\rightarrow$ 特征/匹配/跟踪 $\rightarrow$ PnP、三角化等初值 $\rightarrow$ 非线性优化 $\rightarrow$ 更准确的位姿与地图

同一个思想会在后续章节反复出现：第 7 讲的 PnP、ICP 会使用优化细化结果；第 10 讲的 BA 同时优化相机与地图点；回环之后的位姿图优化则把整条轨迹的约束放在同一张图中求解。

六、从重投影误差到 BA

若第 i 个相机观测到第 j 个地图点，BA 的目标可写作：

$$\min_{\{T_i, P_j\}} \sum_{\{i,j\}} \|z_{ij} - h(T_i, P_j)\|^2$$

它不是逐帧修正，而是让所有相机、所有点和所有观测互相一致。因而 BA 能把局部几何估计统一成全局更合理的解释；代价是变量规模大、结构稀疏，实际实现需要利用稀疏线性代数。

位姿图优化则把节点看作相机位姿、边看作帧间相对位姿约束。发现回环后，新增的一条远距离约束可分散整条轨迹的累计漂移。它与 BA 共享“残差 + 最小二乘 + 迭代线性化”的核心。

七、工程工具：Ceres 与 g2o

Ceres Solver 适合通用非线性最小二乘。开发者定义代价函数 (Cost Function)、参数块 (Parameter Block)、可选鲁棒核与边界，库负责求导、线性求解和 LM 等优化流程。

g2o 更强调图优化建模：顶点是待估计变量，边是观测约束，边的误差函数形成总体目标。它非常贴合位姿图与 BA 的稀疏结构。

两者都不会替你解决建模错误或初值过差的问题。实践前先明确：变量是什么、观测是什么、残差如何定义、信息矩阵/权重来自哪里、异常匹配如何处理。

八、鲁棒性与常见误区

平方损失会放大离群点：一条错误匹配可能主导优化方向。实际系统常在 RANSAC 预剔除后，再在优化中引入 Huber、Cauchy 等鲁棒核。还应关注：初值敏感、局部极小、尺度不一致、雅可比符号错误、观测权重不合理及不可观性。

第六讲并不是要寻找所有非凸问题的全局最优解。它提供的是一套在当前解附近不断建立近似、接受可信更新的通用工具。

九、学习时应抓住的五件事

1. Residual：预测观测与实际观测之差，例如重投影误差。
2. Cost Function：将全部残差组合成一个要最小化的目标，最常见是平方和。
3. Jacobian：局部灵敏度；它把非线性问题在当前点变成可解的线性近似。
4. Gauss-Newton：用 $J^T J$ 近似 Hessian，解正规方程得到增量。
5. LM：以阻尼或信赖域调节 GN 的激进程度，改善收敛稳定性。

十、一个可复述的理解框架

SLAM 有未知量（相机位姿 T 、地图点 P ）和大量观测。由于噪声，观测与模型预测不一致，形成残差。把残差平方和定义为代价函数后，因为投影与运动模型是非线性的，只能在当前估计附近线性化，利用 Jacobian 求一个增量；反复迭代，直至代价不再显著下降。

前端给初值，后端用非线性优化让全部约束一起“对齐”。这正是第六讲与 PnP、BA、回环图优化相连的主线。

自检问题

- 为什么单个重投影误差通常不能完全为零？
- 写出 $r(x + \Delta x)$ 的一阶近似，并解释 J 的含义。
- GN 的正规方程是什么？为什么 H 可能导致数值问题？
- LM 的 λ 增大时，行为更接近哪种方法？
- BA 与位姿图优化分别把哪些变量和约束放进同一目标？

依据：用户提供的学习笔记与本机 Downloads/ch06非线性优化 中 12 张课程截图（最小二乘、GN、LM、Ceres、g2o）。