第十讲：后端总结

从带噪声观测到一致的轨迹与地图：滤波、BA、消元与边缘化

一句话：前端建立观测关联并给出初值；后端把这些带噪声的约束放在一起，估计状态及其不确定性。它不是把轨迹画得更平滑，而是让预测与观测在可信度加权后尽可能一致。

一、这一讲怎样连接前面的内容

第 3 讲解决“用什么表示位姿”，第 6 讲解决“怎样迭代调整状态”，第 7-8 讲提供匹配、几何或光度约束。第 10 讲把这些约束组织成状态估计问题，并利用结构降低计算量。后端并不限于独立线程；前端跟踪中也可能执行小规模优化。

二、状态、输入、观测和噪声

运动：$s_k=f(s_{k-1},u_k)+w_k$
观测：$z_{kj}=h(T_k,P_j)+v_{kj}$
滤波联合状态可写成 s_k=(当前位姿、路标、必要的速度 / 偏置等)。

T 是位姿，P 是地图点，u 是 IMU、轮速等输入，z 是像素或距离观测。纯视觉系统可以不显式加入独立运动因子，但仍需要多帧观测与初始化。用 s 表示完整状态，避免课件把“位姿”和“位姿加地图”都记成 x 的冲突。

三、滤波与优化：保留哪些状态，何时更新

方式	主要保留什么	新数据到来时
滤波（KF / EKF）	当前联合状态的均值、协方差；历史压缩为后验	递推预测和观测更新
批量 / 平滑优化	一组历史位姿、路标及对应约束	对保留的变量联合求解，可重新线性化
滑动窗口优化	有限窗口变量及旧信息形成的先验	加入新帧，优化，再边缘化旧变量

“递增运行”不等于“必然采用滤波”：优化也可以增量执行。批量 BA 也不一定一次处理整段视频，局部 BA 可以在运行过程中反复调用。二者不是单纯的在线 / 离线划分。

四、概率主线：预测是先验，观测用于修正

在状态满足一阶马尔可夫性、观测按状态条件独立的模型下，先对上一时刻的后验做状态转移，再用新观测似然相乘并归一化。历史并没有消失，而是通过后验继续影响当前估计。

预测：$p(s_k|\text{历史})=\int p(s_k|s_{k-1},u_k)p(s_{k-1}|\text{历史})ds_{k-1}$
更新：$p(s_k|\text{历史},z_k) \propto p(z_k|s_k)p(s_k|\text{历史})$

KF：五个公式背后的直觉

线性模型 + 高斯噪声：用均值和协方差完整描述后验。

五、先统一符号，不要只背 Q / R 的名字

本总结采用常见约定：运动噪声 Cov(w)=Q，观测噪声 Cov(v)=R。课件主体采用相反命名，且小结中有局部混用；判断时必须看噪声属于哪条方程。下标 k 可随时间变化。[1]

线性模型：$s_k=A_k s_{k-1}+B_k u_k+w_k$，$z_k=C_k s_k+v_k$
m 为均值，P 为状态协方差；“-”表示当前观测前，“+”表示当前观测后。

六、预测两步，更新三步

1. $m_k^-=A_k m_{k-1}^+ +B_k u_k$
2. $P_k^-=A_k P_{k-1}^+ A_k^T+Q_k$
3. $K_k=P_k^- C_k^T(C_k P_k^- C_k^T+R_k)^{-1}$
4. $m_k^+=m_k^-+K_k(z_k-C_k m_k^-)$
5. $P_k^+=(I-K_k C_k)P_k^-$

运动模型把位置往前推，Q 描述额外的不确定性。创新 $v=z-Cm^-$ 是“真实观测减去预测观测”，K 把创新转换为状态修正。观测提供的约束只降低可观测方向的不确定性，不能凭空确定所有自由度。

七、一个一维例子：到底信谁多一些

预测位置 $m^-=10$ m，方差 $P^-=4$ m²；传感器读数 $z=12$ m，方差 $R=1$ m²，$C=1$。则 $K=4/(4+1)=0.8$，更新后 $m^+=11.6$ m，$P^+=0.8$ m²。读数较可靠，所以向读数移动较多。若 $R=16$ m²，则 $K=0.2$，位置只更新到 10.4 m。

不是简单取平均，而是按不确定性融合。矩阵情形的 K 同时处理方向和状态相关性，不能笼统理解成一个固定百分比。

八、信息形式：与最小二乘建立联系

高斯先验与高斯似然相乘，等价于相加负对数中的二次型。在线性情况下，其后验均值也可由加权最小二乘求得：

$$\min_s \tfrac{1}{2}(s-m^-)^T(P^-)^{-1}(s-m^-)$$
$$+\tfrac{1}{2}(z-Cs)^T R^{-1}(z-Cs)$$
$$(P^+)^{-1}=(P^-)^{-1}+C^T R^{-1} C$$

实际程序应通过矩阵分解解方程，避免显式求逆。协方差更新可用 Joseph 形式：$(I-KC)P^-(I-KC)^T+KRK^T$，减轻浮点误差造成的非对称或非正定问题。以上“最优”依赖正确的线性高斯模型，不可直接推广为 EKF 的全局最优保证。

EKF：非线性系统的局部近似

用非线性函数算预测值，用雅可比传播局部不确定性。

九、为什么视觉 SLAM 不能直接套线性 KF

旋转组合、透视投影 X/Z、畸变等使 f、h 为非线性函数。高斯随机变量经过非线性函数后，通常不再严格为高斯；EKF 在估计附近一阶展开，继续用均值与协方差近似后验。

$F_k=\partial f/\partial s$，取值点为上一时刻后验均值 m_{k-1}^{+}
$H_k=\partial h/\partial s$，取值点为当前预测均值 m_k^{-}

$$m_k^{-}=f(m_{k-1}^{+},u_k)$$
$$P_k^{-}=F_kP_{k-1}^{+}F_k^{T}+Q_k$$
$$K_k=P_k^{-}H_k^{T}(H_kP_k^{-}H_k^{T}+R_k)^{-1}$$
$$m_k^{+}=m_k^{-}+K_k[z_k-h(m_k^{-})]$$
$$P_k^{+}=(I-K_kH_k)P_k^{-}$$

这里假设加性、独立、零均值噪声。噪声若通过非线性函数进入，应另用噪声雅可比传播协方差。公式中的普通加法适用于欧氏状态；旋转 / SE(3) 实现需使用误差状态或流形更新，不能直接给旋转矩阵加一个向量。

十、EKF-SLAM 为什么要保存交叉协方差

状态包含当前机器人和地图路标，P 的非对角块描述“机器人误差与路标误差如何共同变化”。再次看到旧路标时，创新不只修正该路标，还会通过这些相关性修正机器人及其他路标。不能把 P 简化成互不相关的一串方差。

若联合状态维度为 d，完整协方差存储约为 $O(d^2)$。地图路标不断增加时，经典 EKF-SLAM 的存储和更新成本变高；这不意味着所有滤波器都必须保存完整历史轨迹。固定维度的传感器融合滤波是另一种设置。

十一、优势与边界

优势	风险	工程应对
递推清楚，便于多传感器融合	初始化差、强非线性会放大近似误差	正确初始化；必要时迭代更新
显式维护不确定性	噪声估错、错误匹配会导致过度自信或发散	创新门限、离群检查、噪声建模
历史压缩，不必反复处理原始数据	旧线性化信息难以完整重新计算	关注一致性、可观测性及 FEJ

澄清：采用马尔可夫运动模型，不等于 BA 必须使用非马尔可夫运动模型；平滑优化同样可使用相邻状态的马尔可夫因子。EKF 的问题是模型、线性化与历史压缩等共同作用，而不是“一阶马尔可夫假设必然错误”。

BA：把观测组织成稀疏问题

不只调一帧相机，而是联合调整保留的相机和三维点。

十二、重投影残差与目标函数

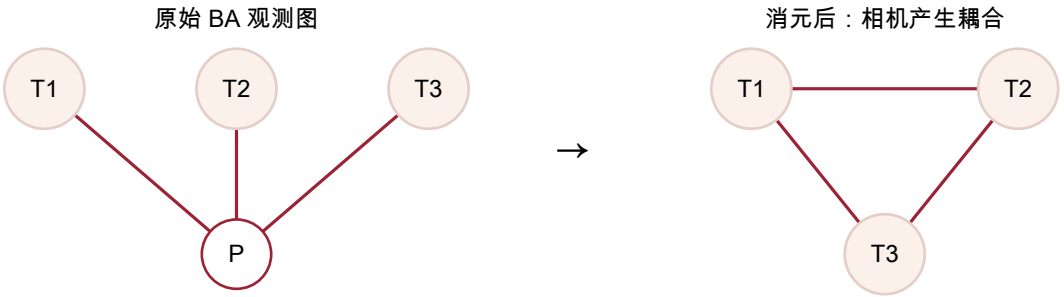
约定 T_i 把世界点转换到第 i 帧相机系。固定内参时，预测像素为 $h(T_i,P_j)=\pi(KT_iP_j)$，π 包含透视除法。只对实际存在且通过筛选的观测集合 O 求和，不是所有相机与点的笛卡尔积。

$$e_{ij}=z_{ij}-h(T_i,P_j)$$
$$\min_{\{T,P\}} \tfrac{1}{2}\Sigma_{(i,j)\in O}\ \rho(e_{ij}^{T}\Omega_{ij}e_{ij})，\Omega_{ij}=\Sigma_{ij}^{-1}$$

Σ 是观测协方差，Ω 是信息矩阵。独立高斯噪声且无鲁棒核时得到加权最小二乘；加入先验则对应 MAP 估计。鲁棒核降低异常残差影响，但不能代替正确匹配。先白化残差，再设置合理阈值，避免混用像素与米。

十三、图结构就是计算结构

位姿、路标是变量节点，每条观测是连接一个相机和一个路标的残差因子。一个点被多帧看到，就把这些帧联系起来。图优化是组织非线性最小二乘问题的方式；BA 是其中一种问题，位姿图不是 BA 的同义词。



示意图仅表达连接关系，不是实测轨迹；右图为线性消元后的耦合，不表示已把 BA 近似成若干独立的位姿图边。

十四、雅可比为什么稀疏

固定内参时，一个二维像素残差只对 T_i 的局部 6 维扰动和 P_j 的 3 维坐标有导数，其余列为零。共有 m 帧、n 点，则增量维度为 6m+3n。纯重投影 BA 的相机块和路标块分别块对角，交叉块由可见关系决定。

$$e(x\boxplus\delta)\approx e(x)+J\delta$$
$$H=\Sigma J_{ij}^{T}\Omega_{ij}J_{ij}，g=\Sigma J_{ij}^{T}\Omega_{ij}e_{ij}$$
GN 解 $H\delta=-g$；LM 解 $(H+\lambda D)\delta=-g$，并检查候选步。

⊞ 表示流形上的状态更新。H 是 GN 近似 Hessian，不是一般非线性目标的精确二阶导数。加入 IMU、相机运动因子、共享内参或边缘化先验后，块结构会改变，不能一概声称所有 BA 的相机块都对角。

Schur 消元：先求相机，再回代点

利用地图点多、点块互不直接关联的结构，缩小每次线性求解。

十五、将变量排成“相机在前，路标在后”

$H = [\, B\ E\ ;\ E^T\ C\,]$，$\delta=(\delta c,\delta p)^T$，右端 $q=-g$

$B\delta c+E\delta p=q_c$

$E^T\delta c+C\delta p=q_p$

块	尺寸（固定内参）	含义
B	6m × 6m	相机变量之间的局部信息
C	3n × 3n	路标块；标准 BA 为各点的 3×3 块对角
E	6m × 3n	相机和点的观测耦合，通常块稀疏

十六、由第二行消去路标增量

$\delta p=C^{-1}(q_p-E^T\delta c)$

$S=B-EC^{-1}E^T$（Schur 补）

$S\delta c=q_c-EC^{-1}q_p$

先解 δc，再回代求 δp，最后更新相机与点。

C 为块对角时，可分别解各点的小方程，而不构造巨大的 C 逆矩阵。上式要求被消元块可解；低视差、单次观测或退化点可能导致奇异，应筛点、加合理约束或在 LM 阻尼后的系统上求解。全局规范自由度也要单独处理。

十七、消元以后为什么出现相机间非零块

同一个点连接多帧时，$EC^{-1}E^T$ 将这些相机耦合起来，S 反映共视关系。消去一个共享节点，通常会在其邻居间产生新连接，这叫 fill-in（填充）。消元会降低稀疏度，但并不必然令 S 完全稠密。

标准 BA：原始相机块可为块对角 → 消去共同路标 → 共视相机产生耦合 → 解更小的相机系统 → 恢复路标增量。

十八、不要把“先消元”理解成“不优化路标”

Schur 消元在当前线性化系统上进行代数重排；精确求解和回代得到与完整线性系统一致的增量。路标仍参与原始非线性问题，下次迭代仍可以重算其残差和雅可比。这也不同于固定路标只调相机的 pose-only 优化。[2]

Ceres 提供 DENSE_SCHUR、SPARSE_SCHUR、ITERATIVE_SCHUR；它们处理缩减系统的方式不同。选择应依据规模、稀疏性、内存和编译后端，而非看到“Schur”就认定某一种必然最快。[2]

边缘化与 FEJ：不能凭空增加信息

减小状态规模时，保留信息，也保留线性化带来的限制。

十九、同一个消元公式，两种不同用途

用途	被消去的变量	以后还能否重新线性化
BA 线性求解加速	本轮暂时消去点，随后回代	原变量 / 因子保留，可在下一轮重算
滑窗边缘化	从活动集合移除旧相机 / 点	相关旧因子压缩为局部先验，通常无法原样重算

在线性高斯信息形式中，积分掉部分变量可用 Schur 补得到剩余变量的信息。非线性滑窗通常先线性化，再形成二次先验：它保留局部近似信息，不等于保留完整非线性后验。不能把“信息都跑到相机里”理解成无损恢复所有旧原始数据。

二十、可观测性：哪些东西本来就不知道

无绝对定位先验时，视觉重建通常无法确定世界坐标原点和朝向；单目还缺少绝对尺度。这些规范自由度形成零空间。固定参考位姿、约束尺度或加真实先验是选坐标 / 提供信息，不是算法从图像里自动测出绝对位置。

不一致的线性化可能把本不可观测的方向伪装成可观测：协方差看起来变小，但真实误差未相应下降，即过度自信。边缘化先验固定在旧线性化点，而新因子不断重线性化时，要特别关注这一问题。

二十一、课件 xy 示例：为什么零空间会消失

令两个相同残差都为 r(x,y)=xy-1，则 E=2(xy-1)²。xy=1 是一条等代价曲线。若两个残差在同一点线性化，两行雅可比相同，J 的秩为 1，保留一个局部零方向。

分别在 (0.5,1.4) 和 (1.2,0.5) 线性化：
J_1=[1.4,0.5]，J_2=[0.5,1.2]
堆叠矩阵的行列式 = 1.4×1.2-0.5×0.5 = 1.43 ≠ 0。
两行不再平行，局部零空间被人为消除；这是课件的一致性警示，不是新增了真实观测。

二十二、FEJ 的作用与边界

FEJ（First-Estimates Jacobian）对特定状态的相关雅可比使用一致的首次估计参考，以维护正确的不可观测子空间。它不是“所有量永远不更新”，也不是所有边缘化都必须机械地套同一个 FEJ 实现；具体规则取决于滤波 / 滑窗模型、误差状态和先验处理。[4]

工程上至少记录：先验参考点、残差重线性化规则、位姿扰动方向与规范约束。FEJ 解决的是一致性问题，不能修复错误匹配、失效标定或缺失的米制尺度。

落地理解：工具与训练数据验收

下面是工程补充；不把课件概念说明写成已经完成的程序实验。

二十三、Ceres / g2o 都要先把问题定义对

Ceres 用参数块与残差块表达问题，支持自动求导、鲁棒损失和流形；g2o 以变量顶点、约束边及信息矩阵表达图优化。它们负责数值求解，不负责替你发现正确对应关系、选择坐标系或补齐尺度。[3][5]

检查输入与关联 → 明确位姿方向 / 单位 → 建立残差和权重 → 约束规范自由度 → 核对雅可比 → GN / LM 求解 → 查看收敛与异常 → 导出轨迹及质量指标

实现核对：① 用有限差分检查解析雅可比；② 用小问题比较 Schur 与完整求解增量；③ 注入离群点验证鲁棒机制；④ 检查相机前方深度、矩阵秩和参考约束；⑤ 保留 cost、停止原因和失败片段，不能只看一条漂亮曲线。

二十四、对具身训练数据建设，优先检查什么

质量维度	需要记录 / 验收	不能误认为什么
坐标与尺度	Tcw / Twc、轴方向、单位、时间戳与有效帧	z 轴矫正或平滑不等于恢复米制尺度
观测支持	有效关联数、空间覆盖、视差、遮挡和动态物体	匹配点多不等于约束充分
局部一致性	重投影残差的中位数 / 尾部、正深度、优化前后变化	代价下降不等于真值误差下降
长期漂移	回环几何验证；有真值时测 ATE / RPE 并注明对齐方式	轨迹平滑不等于全局一致
不确定性与可用性	噪声模型、先验、失败标记及片段筛选策略	置信度分数不必然是统计协方差

这些是工程验收建议，不声称本次已评估某个视频或重跑 SLAM。即使以学习模型提供初值，后端仍只能在模型与观测支持的范围内改善结果；内参偏差、运动物体和错误回环都可能被优化成一组错误但低残差的状态。

二十五、学习时抓住这五句话

1. 后端估计的是状态及不确定性，不只是曲线。
2. KF / EKF 递推先验与观测；EKF 是局部近似。
3. BA 联合调相机和路标，图连接决定雅可比稀疏性。
4. Schur 缩小线性系统，路标增量仍要回代。
5. 滑窗边缘化留下局部先验，需警惕填充与一致性。

材料与核对来源

本机 Downloads/ch10后端 全部 29 张 JPG 已逐一阅读（20261012-152308 至 20261012-152824，课件页 2-30）。未发现独立笔记文本；全文基于图片文字、公式与示意。课堂原图不上传。逐文件内容索引见本目录 README。整理日期：2026-10-12。

[1] Welch & Bishop，An Introduction to the Kalman Filter：KF / EKF 基本推导。

[2] Ceres 官方求解文档：BA 块结构、Schur 补与求解器。

[3] Ceres 官方教程：重投影残差、鲁棒损失与 BA 示例。

[4] Huang 团队 FEJ 技术报告：线性化、可观测性与估计一致性。

[5] g2o 官方仓库；十四讲作者第十讲示例。